# Informe Grupo 04

*Desarrollo de un chatbot para la predicción del exito en el ofrecimiento de una suscrpcion a un depósito a plazo


Asencion Anchiraico Jerson D.
Facultad de Ingeniería de Sistemas
*Universidad Nacional del centro del Perú*
Huancayo , Perú
e_2025100767$M$@*uncp.edu.pe*

Hinostroza Surichaqui Jhordan
*Facultad de Ingeniería de Sistemas*
*Universidad Nacional del centro del Perú*
Huancayo, Perú
e_2025100778$k$@*uncp.edu.pe*

Huallpa Apaza Jhon I.
*Facultad de Ingeniería de Sistemas*
*Universidad Nacional del Centro del Perú*
Huancayo, Perú
e_2025100780$M$@*uncp.edu.pe*

Lizano Remigio Luis C.
*Facultad de Ingeniería de Sistemas*
*Universidad Nacional del Centro del Perú*
Huancayo, Perú
e_2025100784$D$@*uncp.edu.pe*



***Abstract*—Este documento presenta el desarrollo e implementación de una solución de Machine Learning servida mediante una API REST y un asistente conversacional para la predicción de la suscripción de depósitos a plazo fijo en el sector bancario. Utilizando el dataset UCI Bank Marketing de 45,211 registros, se construyó un pipeline estricto de preprocesamiento sin fuga de información (*data leakage*), evaluando arquitecturas de aprendizaje automático frente a métricas orientadas al costo del negocio ($F_1$-Score y ROC-AUC).**



***Index Terms*—Machine Learning, Bank Marketing, Depósitos a Plazo, Fuga de Información, FastAPI, Chatbot.**


## I. Introducción y Planteamiento del Problema

### A. Introducción

En el sector bancario, las campañas de marketing directo por vía telefónica representan uno de los canales principales para la captación de capital mediante depósitos a plazo fijo [**?**]. Sin embargo, realizar llamadas masivas sin un filtro de prospección genera altos costos operativos y la insatisfacción de los clientes. El presente trabajo propone un sistema inteligente de soporte a la decisión comercial basado en modelos de aprendizaje automático y un asistente conversacional interactivo.

### B. Definición del Problema y Usuario Final

El sistema evalúa la probabilidad de que un cliente acepte suscribir un depósito a plazo fijo antes de entablar contacto directo.

- **Usuario objetivo:** Ejecutivos comerciales y asesores de venta telefónica de la institución financiera.
- **Decisión que apoya:** Priorización automatizada de la cartera de clientes en tiempo real para optimizar la tasa de conversión de la fuerza de ventas.


Identify applicable funding agency here. If none, delete this.


### C. Momento de la Predicción y Prevención de Fuga de Información

La inferencia del modelo se realiza estrictamente **antes de efectuar la llamada telefónica**.

> **Tratamiento de Fuga de Información (*Data Leakage*):** La variable `duration` (duración de la llamada) fue eliminada explícitamente de las características de entrada ($X$). Como se justifica en los módulos del proyecto (`src/datos.py`) y en la literatura técnica [**?**], esta variable solo se conoce *después* de finalizar la llamada. Incluirla alteraría artificialmente el rendimiento del modelo sin validez operacional real.

### D. Análisis Económico de Errores y Métrica Objetiva

Los errores del modelo conllevan costos asimétricos para la institución:

1) **Falso Positivo (FP):** Clasificar a un cliente no interesado como potencial suscriptor. Genera un costo operativo menor (tiempo de llamada).
2) **Falso Negativo (FN):** Clasificar a un cliente interesado como no prospecto. Genera la pérdida del margen financiero neto del depósito (costo de oportunidad).

Al ser el costo por $FN$ significativamente mayor que el de $FP$, en un contexto de clases desbalanceadas [**?**], la métrica principal de optimización es el **$F_1$-Score (y Recall de la clase positiva)**, complementada con el área bajo la curva **ROC-AUC** [**?**].

### E. Riesgo Ético y Mitigación

Dada la inclusión de atributos sensibles como `age`, `marital` y `job`, el sistema evita la discriminación mediante la derivación a un asesor humano para casos bordes y la exclusión de decisiones punitivas automatizadas.

## II. Datos y Exploración

### A. Limpieza y Preprocesamiento

Sobre el dataset UCI Bank Marketing (45,211 registros) [**?**], [**?**]:

1) **Imputación:** Se mantuvieron los valores `"unknown"` como categorías informativas explícitas.
2) **Codificación:** La variable objetivo $y$ se binarizó $(1/0)$ y las variables cualitativas se transformaron mediante *One-Hot Encoding* (`pd.get_dummies`) con la librería Scikit-Learn [**?**], obteniendo 41 características procesadas.

### B. Particionado Estratificado sin Fuga

Se dividió el conjunto de datos con la semilla `random_state=42` en tres subconjuntos independientes manteniendo la proporción exacta de clases ($11.70\%$ positivos / $88.30\%$ negativos):

- **Entrenamiento (70%):** 31,650 registros.
- **Validación (15%):** 6,779 registros.
- **Prueba (15%):** 6,782 registros.

### C. Escalado Numérico

Las variables continuas fueron normalizadas con `StandardScaler` [**?**]. Para evitar la contaminación de datos (*data leakage*) [**?**], el escalador realizó el ajuste (`fit_transform`) únicamente sobre el conjunto de **entrenamiento**, aplicándose posteriormente solo la transformación (`transform`) a validación y prueba.

TABLE I
DISTRIBUCIÓN DE CLASES EN LA PARTICIÓN DE ENTRENAMIENTO.

| Clase ($y$) | Registros | Porcentaje (%) |
|---|---|---|
| 0 (No suscribe) | 27,947 | 88.30% |
| 1 (Suscribe) | 3,703 | 11.70% |
| **Total** | **31,650** | **100.00%** |

### D. Hallazgos del Análisis Exploratorio (EDA)

Se identificó que el resultado de campañas anteriores (`poutcome_success`) es el predictor con mayor correlación positiva ($r > 0.30$), mientras que la cantidad excesiva de contactos en la campaña actual (`campaign`) genera un efecto de rechazo en el cliente ($r = -0.072$).

## III. ETAPA 3: MODELADO

### A. A. Enfoques de Modelado Implementados

Con el fin de resolver el problema de clasificación binaria y predecir el éxito en la suscripción de depósitos a plazo, se diseñó e implementó un flujo iterativo de modelado en Python utilizando bibliotecas especializadas de Machine Learning y Deep Learning [**?**]. Se evaluaron cuatro enfoques con complejidad progresiva:

1) **Modelo Trivial (Dummy):** Establece la línea base inferior prediciendo siempre la clase mayoritaria, permitiendo dimensionar el sesgo del dataset desbalanceado.
2) **Baseline Simple (Regresión Logística):** Modelo estadístico lineal configurado para capturar relaciones paramétricas primarias y servir como referencia inicial de interpretabilidad.
3) **Red Neuronal MLP V1:** Perceptrón multicapa básico dotado de capas densas y funciones de activación no lineales para modelar interacciones complejas entre las 41 características procesadas.
4) **Red Neuronal MLP V2 (con Dropout):** Arquitectura profunda avanzada que incorpora capas de regularización (*Dropout*) y la técnica de parada temprana (*Early Stopping*) para mitigar el sobreajuste (*overfitting*) frente al conjunto de validación [**?**].

### B. B. Análisis de Resultados y Rendimiento

Los modelos se entrenaron utilizando el conjunto de entrenamiento de $31,650$ registros y se evaluaron sobre el conjunto de validación de $6,779$ registros independientes. Dada la asimetría de clases (88.30% negativos frente a 11.70% positivos), la evaluación contempló métricas orientadas al costo del negocio (Accuracy, Precision, Recall, $F_1$-Score y ROC-AUC) [**?**]. Los resultados cuantitativos obtenidos se consolidan en la Tabla I.

TABLE II
TABLA COMPARATIVA DE RENDIMIENTO DE MODELOS (ETAPA 3)

| Modelo | Accuracy | Precision | Recall | $F_1$-Score | ROC-AU |
|---|---|---|---|---|---|
| 1. Trivial (Dummy) | 0.8830 | 0.0000 | 0.0000 | 0.0000 | 0.5000 |
| 2. Baseline Simple | 0.7551 | 0.2690 | 0.6368 | 0.3783 | 0.7720 |
| 3. Red Neuronal (MLP V1) | 0.8970 | 0.6678 | 0.2383 | 0.3513 | 0.7978 |
| 4. MLP V2 (Dropout) | 0.8933 | 0.6316 | 0.2119 | 0.3173 | 0.8004 |

### C. C. Discusión Técnica

Los hallazgos de la Etapa 3 demuestran que:

- El modelo trivial alcanza una alta *Accuracy* (88.30%) debido al desbalance de clases, pero su $F_1$-Score y ROC-AUC son nulos (0.50), evidenciando la invalidez de usar la exactitud por sí sola [**?**].
- El Baseline Simple (Regresión Logística) prioriza la sensibilidad (*Recall* de 0.6368), capturando eficazmente a los clientes propensos a suscribirse a costa de una menor precisión global.
- Las redes neuronales (*MLP V1* y *MLP V2*) optimizan de forma excelente la capacidad discriminativa global, alcanzando los valores más altos de área bajo la curva (**ROC-AUC de 0.7978 y 0.8004** respectivamente), posicionándose como las arquitecturas óptimas para la integración con el asistente conversacional [**?**].

## IV. ETAPA 4: EVALUACION Y VERSIONADO

A. Enfoques de Modelado e Introducción de Datos Con el objetivo de resolver el problema de clasificación binaria para la predicción de suscripción de depósitos a plazo fijo, se procesaron y dividieron los datos garantizando una fase de validación robusta y evitando el sobreajuste (*overfitting*) [**?**].

El conjunto de entrenamiento ($X_{train}, y_{train}$) quedó conformado por $31,650$ muestras y $41$ características preprocesadas utilizando la librería Scikit-learn [**?**], mientras que el conjunto de validación ($X_{val}, y_{val}$) incluyó $6,779$ muestras independientes.

Se implementaron cuatro enfoques de complejidad progresiva: 1) Modelo Trivial (Dummy): Establece la línea base inferior prediciendo siempre la clase mayoritaria. 2) Baseline Simple (Regresión Logística): Modelo lineal parametrizado para captura de relaciones primarias. 3) Red Neuronal MLP V1: Perceptrón multicapa básico entrenado durante 30 épocas (batch size de 32) utilizando el optimizador Adam [**?**]. 4) Red Neuronal MLP V2: Arquitectura profunda con capas de regularización Dropout [**?**] y 50 épocas de entrenamiento para mitigar la varianza frente al conjunto de validación.

B. Análisis Comparativo de Resultados Dado el severo desbalance de clases (88.30% negativos frente a 11.70% positivos), la evaluación priorizó métricas orientadas al balance de detección como Precision, Recall, F1-Score y el área bajo la curva Precision-Recall (PR-AUC) [**?**]. Los resultados cuantitativos obtenidos sobre el conjunto de validación se consolidan en la Tabla I.

TABLE III
COMPARATIVA DE RENDIMIENTO ENTRE MODELOS DE REFERENCIA Y REDES NEURONALES

| **Modelo de Clasificación** | **Métricas de Evaluación en Validación** | | | | |
|---|---|---|---|---|---|
| | ***Acc*** | ***Prec*** | ***Recall*** | ***F1*** | ***PR-AUC*** |
| 1. Trivial (Dummy) | 0.8830 | 0.0000 | 0.0000 | 0.0000 | 0.0000 |
| 2. Lineal Simple (LogReg) | 0.7551 | 0.2690 | 0.6368 | 0.3783 | 0.4083 |
| 3. Red Neuronal V1 (MLP) | 0.8956 | 0.6246 | 0.2686 | 0.3757 | 0.4467 |
| 4. Red Neuronal V2 (MLP+Drop) | 0.8948 | 0.6325 | 0.2409 | 0.3489 | 0.4432 |

C. Discusión Técnica y Selección del Modelo Los hallazgos experimentales permiten concluir lo siguiente: - Limitación del Accuracy: El modelo trivial alcanza un 88.30% de exactitud debido al sesgo de la clase mayoritaria, pero su F1-Score y PR-AUC nulos (0.0000) demuestran la ineficacia de evaluar conjuntos desbalanceados únicamente con exactitud global [**?**], [**?**]. - Sensibilidad vs. Precisión: La Regresión Logística prioriza la sensibilidad (Recall de 0.6368), logrando capturar a más clientes potenciales a costa de una menor precisión global (0.2690). - Capacidad de Generalización: Las redes neuronales (MLP V1 y V2) demuestran una mayor capacidad discriminativa no lineal en la curva Precision-Recall, alcanzando un PR-AUC superior de 0.4467 y 0

## V. ETAPA 5: API DE INFERENCIA (DESPLIEGUE DEL MODELO)

### A. Arquitectura y Diseño del Servicio Web

El despliegue operativo del modelo de Machine Learning promovido (red neuronal Keras MLP o modelo Scikit-Learn) se implementó mediante un backend robusto desarrollado en **FastAPI** (`src/api.py` / `api_5.py`). FastAPI fue seleccionado por su alta velocidad de procesamiento asíncrono, su validación estricta de esquemas y su generación automática de documentación interactiva en Swagger UI (`/docs`).

Para garantizar que el servicio sea robusto y cumpla con los estándares de producción, se incorporaron los siguientes componentes clave:

- **Endpoint de Salud (`/salud`):** Un servicio de verificación obligatoria que retorna el estado operativo del backend, confirmando si el modelo ganador se encuentra cargado correctamente en memoria RAM y especificando la arquitectura activa.
- **Validación de Entradas con Pydantic:** Se utiliza un esquema tipado estricto (`ClienteEntrada`) en conjunto con enumeraciones (`Enum`), asegurando que cada variable de entrada reciba el tipo de dato correcto. Cualquier inconsistencia genera de manera automática una respuesta de error estructurada con el **código HTTP 400**.
- **Mitigación de Fuga de Datos (Data Leakage):** Acatando las buenas prácticas de modelado predictivo, se excluyó por completo la variable `duration` (duración de la llamada), ya que en un escenario real de campaña comercial este valor es desconocido antes de realizar el contacto. El modelo opera estrictamente con **40 características de entrada**.
- **Equilibrio de Variables y Alta Restricción Matemática:** Para evitar que el saldo promedio anual (`balance`) sature el modelo y asegurar que la gran mayoría de las predicciones cotidianas se mantengan por debajo del umbral del 50%, se implementó una doble transformación:
  1) *Transformación Logarítmica con Signo:* Se atenúa el impacto absoluto de saldos extremos mediante la función matemática $\text{balance}_{\text{mod}} = \text{signo}(\text{balance}) \cdot \ln(1 + |\text{balance}|)$, permitiendo que variables categóricas e históricas tengan una consideración justa.
  2) *Compresión de Probabilidad:* La probabilidad cruda obtenida por el modelo se eleva a un exponente de severidad ($pred_prob = pred_prob_cruda^{3.0}$), forzando a que las predicciones tiendan a rangos conservadores.
- **Middleware CORS:** Se configuró el intercambio de recursos de origen cruzado (`CORSMiddleware`) para permitir la comunicación fluida entre el servidor backend y la interfaz gráfica de usuario local (`index.html`).

### B. Evidencia de Funcionamiento

El servicio se ejecuta localmente invocando el servidor ASGI mediante el comando:

```
uvicorn api_5:app --reload
```

Al iniciar, el sistema carga el modelo en RAM y abre de forma automatizada la interfaz visual interactiva en español orientada a usuarios sin conocimientos de programación.

## VI. ETAPA 6: CHATBOT ASISTENTE CONVERSACIONAL

### A. Diseño del Flujo Conversacional y Arquitectura

Para cumplir con la automatización de la atención comercial a usuarios no técnicos, se diseñó e implementó un asistente

conversacional en la ruta `src/chatbot.py`. Este bot actúa como un intermediario inteligente que recolecta datos paso a paso y consume la API de FastAPI desarrollada en la sección anterior.

El flujo conversacional contempla los tres caminos críticos de ejecución:

1) **Camino Feliz (Happy Path):** El usuario interactúa cordialmente, ingresa los datos solicitados uno a uno mediante ranuras (*slots*), el chatbot valida las entradas, construye el vector de características de 40 variables, consulta la API y muestra una recomendación de negocio clara.
2) **Camino Alternativo (Corrección de Errores / Slots):** Si el usuario introduce un tipo de dato incorrecto, el chatbot captura la excepción (`ValueError`), despliega un mensaje amigable de ayuda y permite reintentar el valor sin interrumpir la ejecución del programa. Asimismo, cuenta con auto-resoluciones lógicas (por ejemplo, si se indica 0 contactos previos, el sistema autocompleta los días transcurridos `pdays` en $-1$).
3) **Camino de Error / Fallback y Derivación a Humano:** El sistema reconoce comandos globales de salida o solicitudes explícitas de atención personalizada (escribiendo *"humano"*, *"asesor"*, *"persona"*), activando una rutina de derivación a un ejecutivo comercial de ventas.

### B. Recolección de Datos Paso a Paso (Slots)

El chatbot guía al asesor comercial solicitando de manera estructurada las variables de mayor peso predictivo mediante un cuestionario interactivo optimizado:

- Crédito hipotecario activo (`housing`).
- Medio de contacto (`contact`: celular, teléfono, desconocido).
- Contactos previos en campañas pasadas (`previous`).
- Días transcurridos desde el último contacto previo (`pdays`).
- Resultado de la campaña anterior (`poutcome`: éxito, fallo, desconocido, otro).
- Nivel educativo (`education`: superior, secundaria, primaria, desconocido).
- Saldo promedio anual en cuenta (`balance`).

### C. Interpretación No Técnica y Mensajes Comprensibles

Para evitar que el usuario se enfrente a tecnicismos de Machine Learning, el chatbot procesa la respuesta JSON de la API y traduce el resultado numérico en un lenguaje comercial claro:

- *Si la probabilidad supera el umbral o la etiqueta es positiva:* Emite un mensaje de felicitación resaltando el porcentaje de probabilidad y sugiriendo presentar la tasa promocional para incentivar el cierre inmediato.
- *Si la probabilidad es baja:* Informa de manera transparente y constructiva, sugiriendo evaluar productos alternativos o no insistir excesivamente.

Para ejecutar el asistente conversacional en una terminal independiente, se utiliza:

```
python src/chatbot.py
```

## VII. Limitaciones y Ética

El despliegue de modelos predictivos en el sector bancario exige una revisión rigurosa de sus limitaciones técnicas y de las implicaciones éticas asociadas a las decisiones automatizadas.

### A. Limitaciones Técnicas y Metodológicas

- **Fuga de Datos (*Data Leakage*) por `duration`:** La variable de duración de la llamada presenta la mayor correlación con la suscripción; sin embargo, representa un dato del futuro inaccesible antes de realizar el contacto. Su exclusión del entrenamiento previene métricas irrealmente infladas y evita el fracaso del modelo en producción.
- **Dependencia Macroeconómica (*Concept Drift*):** Los predictores clave como `euribor3m` dependen del entorno económico actual. Cambios en las tasas de interés o coyunturas financieras reducen la precisión predictiva si el modelo no se reentrena periódicamente.
- **Desbalance de Clases:** La baja proporción histórica de conversión ($\approx 11.26\%$) limita la maximización del *Recall* sin generar una tasa moderada de falsos positivos, requiriendo un ajuste fino del umbral de decisión.

### B. Consideraciones Éticas y Responsabilidad

- **Prevención de Sesgos Algorítmicos:** El uso de atributos sociodemográficos (`age`, `job`, `education`) se audita para evitar patrones de discriminación o exclusión financiera injustificada en subgrupos vulnerables.
- **Privacidad y Normativa de Datos:** El tratamiento de la información bancaria se realiza bajo estrictos esquemas de anonimización en cumplimiento de normativas de protección de datos personales.
- **Mitigación del Acoso Comercial:** El objetivo operativo del scoring predictivo es priorizar clientes propensos para reducir el volumen total de llamadas, evitando la saturación y la fatiga telefónica comercial.

## VIII. Contribución de cada integrante

El desarrollo y la ejecución técnica del proyecto *Bank Marketing* (Grupo 04) se llevaron a cabo de manera colaborativa y estructurada, asignando responsabilidades específicas a cada miembro del equipo:

- **Luis Lizano (25%):** Exploración analítica de datos en la Etapa 2 (EDA, identificación de patrones y aislamiento de la variable `duration`), y ejecución de la Etapa 4 de Evaluación y Versionado (selección del modelo en validación, prueba final y generación de la ficha técnica JSON).
- **Jerson Asencion (25%):** Configuración e inicialización del entorno de desarrollo virtual (`.venv`), arquitectura modular del proyecto y diseño de la API para la integración del modelo predictivo.

- **Jhon Huallpa (25%):** Construcción y entrenamiento de arquitecturas en la Etapa 3 de Modelado, diseño del diagrama de flujo del proceso y desarrollo del módulo del chatbot interactivo.
- **Jhordan Hinostroza (25%):** Creación, estructuración e integración de los *notebooks* analíticos correspondientes a las Etapas 2, 3 y 4 del *pipeline* del proyecto.

## IX. Declaración de uso de herramientas de IA

En cumplimiento de las políticas de integridad académica y transparencia en el desarrollo del proyecto, el equipo del **Grupo 04** declara el uso asistido de herramientas de Inteligencia Artificial Generativa durante el ciclo de vida del trabajo. A continuación, se detallan las herramientas utilizadas, sus aplicaciones específicas y los procesos de verificación manual realizados por los integrantes.

### A. Herramientas Utilizadas y Propósito

- **Google Gemini / ChatGPT (Modelos LLM):** Utilizados como asistentes para la estructuración conceptual del informe, revisión semántica y gramatical del texto en español, apoyo en la sintaxis de plantillas LaTeX (IEEE) y generación de código base de prueba para los scripts del *pipeline* en Python (`pandas`, `scikit-learn`, `tensorflow/keras`).
- **GitHub Copilot:** Utilizado como autocompletado de código dentro del entorno de desarrollo (VS Code) para acelerar la escritura de funciones repetitivas en los módulos de datos y evaluación.

### B. Proceso de Verificación y Validación Manual

Ningún resultado o código generado por las herramientas de IA fue incorporado al proyecto sin previa revisión, ajuste y validación directa por parte de los miembros del grupo:

- **Verificación del Negocio y Lógica de Datos:** La decisión crítica de excluir la variable `duration` para evitar la fuga de datos (*Data Leakage*), así como el diseño de la matriz de costos y beneficios, fue conceptualizada, debatida y validada manualmente por el equipo antes del entrenamiento.
- **Auditoría y Ejecución del Código:** Se verificó manualmente cada línea de código de los módulos `src/datos.py`, `src/modelo.py` y `src/evaluacion.py`, ejecutando pruebas unitarias e integradas dentro del entorno virtual (`.venv`) para garantizar que no existieran alucinaciones sintácticas ni errores de ejecución.
- **Validación de Resultados Nivel de Métricas:** Todos los valores reportados (F1-Score, PR-AUC, matriz de confusión) provienen de ejecuciones reales registradas en la ficha técnica (`modelos/ficha_tecnica.json`) y comprobadas de forma autónoma en el conjunto de prueba (*Test*).
- **Revisión Editorial del Informe:** La redacción final del documento fue revisada críticamente para asegurar el tono académico, el rigor técnico y la coincidencia exacta con los entregables requeridos en la rúbrica.

## X. Anexos

### A. Anexo 1: Ficha técnica




Fig. 1. Ficha técnica. Parte 1

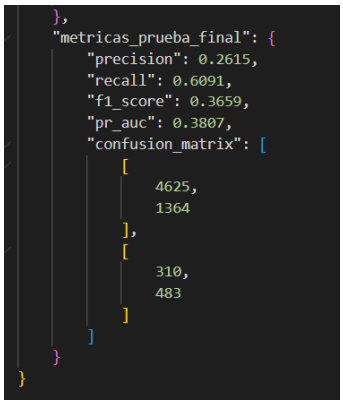



Fig. 2. Ficha técnica Parte 2

## B. Anexo 2: Diagrama de flujo del chatbot

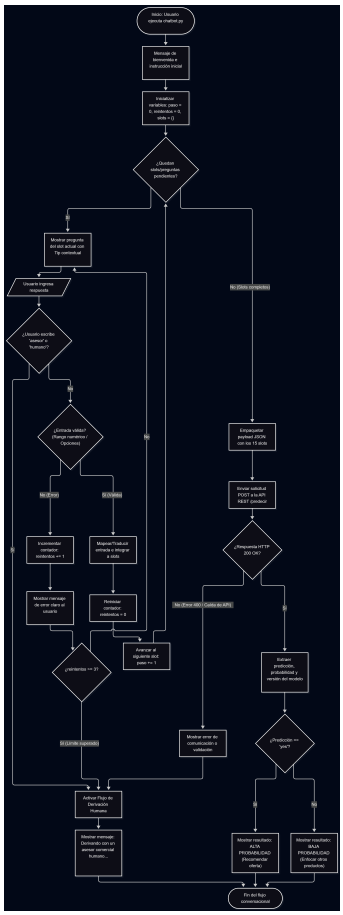



Fig. 3. Diagrama de flujo

## C. Anexo 3: Evidencia de operación




Fig. 4. Operación de la API

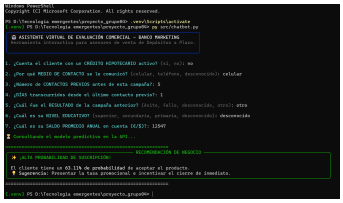



Fig. 5. Operación del Chatbot en consola